Máster en Inteligencia Artificial UMU

Infraestructuras para Deep Learning

Práctica 1: Programación de plataformas de cómputo para DL

1 Objetivos

1. Aprendizaje de librerías y frameworks modernos para aceleración de cargas de trabajo de Deep Learning en CPU y aceleradores.
2. Implementación y evaluación de técnicas de programación paralela para realizar procesos de inferencia y entrenamiento de modelos de Deep Learning.

2 Entornos disponibles

De forma similar a como se ha procedido con otras asignaturas del máster, para poder realizar esta práctica se utilizará fundamentalmente el clúster ATLASv2 de la UMU. No obstante, para aquellas tareas que requieran del uso de una CPU y/o de una GPU, es decir, no requieran de un entorno multi-GPU, se podría utilizar la máquina del estudiante.

2.1 Máquina del estudiante

En este caso, se tendría que disponer de una máquina con Linux y tener instalado el sistema de virtualización Docker. Además, para aquellos que dispongan de GPU propia, tendrá que ser del fabricante NVIDIA.

En la carpeta de Recursos/Práctica1 del Aula Virtual en el fichero comprimido masterIDL_scripts_v2.zip hay un fichero Dockerfile para poder realizar la construcción de la imagen y poder crear el contenedor. Es importante tener en cuenta que tras construir la imagen con el comando:

```
[mi_máquina]$ sudo docker build -f Dockerfile -t accelerate:idl
```

La imagen creada ocupará unos 30 GBytes de espacio en disco y, dependiendo de la potencia de la máquina, su creación puede requerir de bastantes minutos (una media hora si la máquina no es muy potente).

Tras crear la imagen, para poder lanzar el contenedor de manera interactiva se ejecutará el comando:

```
[mi_máquina]$ sudo docker container run --gpus all -it ID_IMAGEN
```

Donde ID_IMAGEN será el identificador de la imagen previamente construida con el Dockerfile y cuyo identificador se podrá consultar con el comando:

```
[mi_máquina]$ sudo docker images
```

Es recomendable entrar de manera interactiva al contenedor para poder testear el entorno de ejecución y su correcto funcionamiento.

2.2 Clúster ATLASv2

Tal y como pudisteis trabajar en el primer cuatrimestre con otras asignaturas, esta solución está basada en el uso de servidores dinámicos proporcionados por el clúster ATLASv2 de la Universidad de Murcia. La novedad principal en esta asignatura de Infraestructuras para Deep Learning es el poder acceder a la cola03, permitiendo la ejecución de vuestros experimentos en nodos con varias GPUs (hasta 4), a los que nos referiremos como nodos multi-GPU. Por tanto, en el enunciado de esta práctica no se repetirá cómo tenéis que acceder al clúster para lanzar experimentos en el clúster (**sbatch**). Para más información, el alumno puede recurrir a la guía del uso del clúster ATLASv2 que se encuentra aquí, y descargar los ejemplos de scripts *sbatch* que ha facilitado el profesor en el fichero comprimido masterIDL_scripts_v2.zip de la carpeta de Recursos/Práctica1 del Aula Virtual.

En ATLASv2 se tienen disponibles las siguientes colas:

- **Cola01 (atlasv2_mia_cpu01):** Recomendable para cómputo con solo CPU.
- **Cola02 (atlasv2_mia_gpu01_1t4)**: Experimentos con una GPU.
- **Cola03 (atlasv2_mia_gpu02_4t4)**: Experimentos con nodos multi-GPU.

En lugar de imágenes Docker como en el apartado anterior 2.1, en el clúster ATLASv2 las imágenes se gestionarán a través de *Apptainer* (sucesor de *Singularity*); ficheros que tienen extensión ".sif". En esta asignatura, el profesor ha dejado una imagen genérica que contiene todo el software necesario para ejecutar los experimentos necesarios para esta práctica con el software *Accelerate* de *Hugging Face*, que será descrito más abajo. Esta imagen se llama "mia_idl_2.2.sif" y se encuentra disponible en el clúster en la carpeta con ruta absoluta: `/software/singularity/Informatica/mia-idl-apptainer/`. Esta imagen Apptainer ha sido construida partiendo del Dockerfile que también se encuentra dentro de esa carpeta.

Los alumnos deberían de poder acceder a esta carpeta tras conexión al clúster mediante el comando siguiente (donde sustituiremos `usuario` por nuestro *login* correspondiente):

```
[mi_máquina]$ ssh usuario@atlas-scc.atica.um.es
```

Es importante señalar que el directorio $HOME de cada usuario dispone de una cuota máxima de almacenamiento de 2 GB. Esto implica que, para experimentos que utilicen datasets o modelos de Deep Learning de gran tamaño, dicho espacio podría resultar insuficiente. Por este motivo, se recomienda utilizar la unidad SCRATCH, disponible en el directorio /scratch de los nodos del clúster. Debe tenerse en cuenta que esta unidad no garantiza la persistencia de los datos (no dispone de copias de respaldo), por lo que la información generada podría perderse una vez finalizados los experimentos. Los resultados finales que deban conservarse deberán almacenarse en el directorio $HOME de cada estudiante. Asimismo, es posible liberar espacio en este directorio eliminando los ficheros ocultos .cache y/o .local, cuando no sean necesarios.

3 Accelerate

Accelerate es una librería de *Hugging Face* sobre PyTorch que permite adaptar fácilmente los procedimientos de entrenamiento e inferencia de nuestros modelos de Deep Learning, para que puedan ejecutarse eficientemente aprovechando las características computacionales de la plataforma de cómputo destino que dispongamos, a la que se denomina comúnmente como el *backend*. Este *backend* puede tratarse tanto de un sistema de cómputo local centralizado (e.g., mi ordenador personal que dispone de una GPU), así como un sistema de cómputo distribuido (e.g., un solo nodo multi-GPU o varios nodos dentro de un clúster *on-premise* o, incluso, nodos virtualizados en el contexto de la computación en la nube (*cloud computing*).

El uso de esta librería es bastante sencillo e intuitivo, lo que reduce notablemente su curva de aprendizaje si se está familiarizado con la ejecución de modelos en PyTorch. Así, partiendo de un código en PyTorch para entrenar un modelo de red neuronal

```python
# 1. Mover el modelo a la GPU para acelerar el entrenamiento
device = "cuda"
model.to(device)
# 2. Iterar sobre los lotes de datos del DataLoader
for batch in training_dataloader:
    # 3. Reiniciar los gradientes del optimizador (se acumulan por defecto en PyTorch)
    optimizer.zero_grad()
    # 4. Obtener los datos de entrada y sus etiquetas
    inputs, targets = batch
    # 5. Mover los datos a la GPU para que coincidan con el dispositivo del modelo
    inputs = inputs.to(device)
    targets = targets.to(device)
    # 6. Hacer la predicción con el modelo
    outputs = model(inputs)
    # 7. Calcular la pérdida comparando la predicción con los valores reales
    loss = loss_function(outputs, targets)
    # 8. Retropropagar la pérdida para calcular los gradientes
    loss.backward()
    # 9. Actualizar los parámetros del modelo usando el optimizador
    optimizer.step()
    # 10. Ajustar la tasa de aprendizaje si se usa un scheduler
    scheduler.step()
```

arbitrario ("model" en la imagen siguiente):

Un tutorial detallado para el aprendizaje y uso de Accelerate se puede encontrar aquí. Se invita al estudiante a que lo revise antes de realizar la práctica. A continuación, se va a explicar lo básico para comprender su funcionamiento y aprovechamiento.

Con Accelerate, el código anterior sería modificado mínimamente delegando a la clase **Accelerator** la selección y uso de un dispositivo acelerador (e.g., la GPU), al que de manera transparente se le transferirán los objetos PyTorch esenciales para el procedimiento de entrenamiento o de inferencia (objetos como model, optimizer, scheduler, etc.). El código resultante aparece en la siguiente imagen:

```python
from accelerate import Accelerator

# Inicializa Accelerator, que gestiona automáticamente el dispositivo (CPU, GPU, TPU)
accelerator = Accelerator()

device = accelerator.device  # No es necesario especificar manualmente "cuda()" o "cpu()"

# Prepara el modelo, optimizador, dataloader y scheduler para entrenamiento en múltiples dispositivos
# Esto reemplaza la necesidad de mover manualmente estos elementos a un dispositivo específico
model, optimizer, training_dataloader, scheduler = accelerator.prepare(
    model, optimizer, training_dataloader, scheduler
)

for batch in training_dataloader:
    optimizer.zero_grad()
    inputs, targets = batch

    # No es necesario mover nada al dispositivo acelerador ya que el nuevo training_dataloader lo hará
    #inputs = inputs.to(device)
    #targets = targets.to(device)

    outputs = model(inputs)
    loss = loss_function(outputs, targets)

    # Accelerate maneja la sincronización automática del gradiente si entorno distribuido
    accelerator.backward(loss)

    optimizer.step()
    scheduler.step()
```

A continuación, lo único que se tendría que hacer para poder lanzar el proceso de entrenamiento sobre un *backend* particular, como por ejemplo una GPU, sería con la siguiente línea de comandos:

```
accelerate launch {my_script.py}
```

Donde {my_script.py}, sería el nombre del fichero del código anteriormente ilustrado.

Lo que faltaría por definir sería el tipo específico de *backend* a utilizar ya que, como se puede observar, no se ha especificado todavía.

Una de las opciones más recomendable para la definición del backend a usar, es la de añadir opciones específicas que lo definan en la línea de comandos de lanzamiento (`accelerate launch` **[+OPCIONES]**). Por ejemplo, si quisiéramos lanzar sobre la GPU0 de nuestro nodo de cómputo que tiene varias GPUs, escribiríamos en línea de comandos:

```
$> CUDA_VISIBLE_DEVICES=0  accelerate launch --num_processes 1 m_script.py
```

Ahora bien, si quisiéramos ejecutarlo únicamente sobre la CPU de mi nodo de cómputo, simplemente cambiaríamos la línea de comandos anterior por esta:

```
$> accelerate launch --cpu --num_processes 1 m_script.py
```

Como puede apreciarse, Accelerate facilita notablemente la portabilidad del código de entrenamiento e inferencia de nuestros modelos PyTorch para distintos *backends*.

Además, en entornos de ejecución propios (como la máquina del estudiante), en los que disponemos de un único *backend* en el que siempre vamos a ejecutar nuestros modelos DL, Accelerate también ofrece la posibilidad de añadir al código PyTorch de nuestros modelos modificaciones mínimas para definirlo. Esto, como se puede entender, reduce la portabilidad de nuestro código, pero puede sernos útil si no la necesitamos. Por ejemplo, si queremos forzar la ejecución de nuestro código sobre nuestro *backend* de CPU, podríamos simplemente especificarlo en código al crear el objeto "Accelerator", cambiando la línea 4 de la imagen anterior por:

```
Accelerator= Accelerator(cpu=True)
```

No obstante, para selección de *backends* a los que tengamos acceso que tengan características más específicas (lo veremos más adelante), existe la opción "config" de Accelerate:

```
accelerate config
```

Así, tras ejecutar el comando anterior, nos aparecerán una serie de preguntas que nos ayudarán a definir el *backend* concreto de ejecución que quedará almacenado en un fichero con extensión ".yaml":

```
root@39229ceb2b9d:/accelerate_gpu# accelerate config
----------------------------------------------------------------
In which compute environment are you running?
This machine
```

De este modo, disponemos de gran variedad de *backends* a elegir entre los siguientes:

```
Which type of machine are you using?
Please select a choice using the arrow or number keys, and selecting with enter
 ➜  No distributed training
    multi-CPU
    multi-XPU
    multi-GPU
    multi-NPU
    multi-MLU
    multi-MUSA
    TPU
```

1. ***No distributed training***: Configura el entorno para ejecutar entrenamiento en un solo dispositivo sin distribución (seleccionar un único dispositivo de cómputo como una CPU o una GPU).
2. ***multi-CPU***: Habilita el entrenamiento distribuido utilizando múltiples CPUs en paralelo.

3. ***multi-XPU***: Configura el entrenamiento distribuido en múltiples aceleradores compatibles con Intel XPU (arquitectura de cómputo heterogénea que combina CPU, GPU y FPGA)
4. ***multi-GPU***: Permite la distribución del entrenamiento en varias GPUs para mejorar el rendimiento.
5. ***multi-NPU***: Configura el entrenamiento distribuido en múltiples NPU (*Neural Processing Units)*.
6. ***multi-MLU***: Habilita el entrenamiento en múltiples MLU (Cambricon Machine Learning Units; aceleradores creados para DL por la empresa Cambricon).
7. ***multi-MUSA***: Configura el entrenamiento distribuido en múltiples aceleradores MUSA (*Mthreads Unified System Architecture*; aceleradores creados para DL por la empresa Mthreads).
8. ***TPU***: Permite el uso de Tensor Processing Units (TPU) para el entrenamiento distribuido de modelos de machine learning.

Entre todas estas opciones, para resolver la práctica bastará con las opciones 1 (permite distinguir entre CPU o GPU; colas 01 y 02) y la opción 4 (cola03).

A modo de curiosidad, se puede comprobar qué configuración tendría nuestra máquina usando el siguiente comando:

```
accelerate env
```

Además del tipo de *backend*, cuando se selecciona una de las 8 opciones anteriores, Accelerate brinda la posibilidad de elegir entre frameworks/librerías para optimizar la ejecución de nuestros programas PyTorch como son las de IPEX, Torch Dynamo, DeepSpeed, *mixed precision*, entre otras que serán descritas más abajo.

También tiene la opción para uso de Amazon SageMaker, servicio de Amazon Web Services (AWS) para entrenamiento e inferencia de modelos DL escalable y automatizado en la nube (un servicio de *cloud computing*).

Tras la ejecución del comando "accelerate config" con la opción de ejecución deseada, Accelerate almacena dicha configuración en el fichero default_config.yaml dentro de la carpeta siguiente:

```
$HOME/.cache/huggingface/accelerate/
```

De este modo, cuando se ejecuta el código con nuestro código PyTorch (e.g., my_script.py):

```
accelerate launch {my_script.py}
```

Accelerate leerá la configuración almacenada en default_config.yaml de nuestra carpeta local para escoger el *backend por defecto* configurado para ejecución.

Además, Accelerate ofrece la posibilidad de definir un fichero de configuración "yaml" para cada *backend* al que tengamos acceso para no tener siempre que estar ejecutando

nuestros experimentos en el *backend* por defecto. Así, una buena praxis sería crear un fichero de configuración ".yaml" para cada cola de ATLASv2 (colas 01, 02 y 03).

Por ejemplo, si queremos ejecutar el procesamiento de entrenamiento anterior en GPU (cola 02), ejecutaríamos la línea de comandos que aparece en la imagen siguiente e iríamos escogiendo las opciones de configuración siguientes (por simplicidad, se omiten algunos pasos de configuración):

```
root@f0dae4912802:/accelerate_gpu# accelerate config --config_file config_gpu.yaml
----------------------------------------------------------------------------------------------------------------------------
In which compute environment are you running?
This machine
----------------------------------------------------------------------------------------------------------------------------
Which type of machine are you using?
No distributed training
Do you want to run your training on CPU only (even if a GPU / Apple Silicon / Ascend NPU device is available)? [yes/NO]:NO
Do you wish to optimize your script with torch dynamo?[yes/NO]:NO
Do you want to use DeepSpeed? [yes/NO]: NO
What GPU(s) (by id) should be used for training on this machine as a comma-seperated list? [all]:all
Would you like to enable numa efficiency? (Currently only supported on NVIDIA hardware). [yes/NO]: NO
----------------------------------------------------------------------------------------------------------------------------
Do you wish to use mixed precision?
no
accelerate configuration saved at config_gpu.yaml
```

Tras esto, se crearía un fichero llamado "config_gpu.yaml" cuyo contenido sería el siguiente:

```
root@f0dae4912802:/accelerate_gpu# cat config_gpu.yaml
compute_environment: LOCAL_MACHINE
debug: false
distributed_type: 'NO'
downcast_bf16: 'no'
enable_cpu_affinity: false
gpu_ids: all
machine_rank: 0
main_training_function: main
mixed_precision: 'no'
num_machines: 1
num_processes: 1
rdzv_backend: static
same_network: true
tpu_env: []
tpu_use_cluster: false
tpu_use_sudo: false
use_cpu: false
```

Finalmente, podríamos lanzar nuestro experimento de entrenamiento de la siguiente forma especificando con --config_file el fichero anterior de configuración:

```
$> accelerate launch --config_file config_gpu.yaml ModeloDL.py
```

3.1 Ejecución de inferencia y entrenamiento de modelos DL

El proceso de ejecución de la inferencia y entrenamiento de modelos DL definidos en PyTorch con Accelerate es bastante sencillo. A modo de ejemplo, vamos a utilizar un modelo del dominio de aplicación de visión por computador para clasificación de imágenes como es el modelo convolucional ResNet-50. El procedimiento de inferencia para ResNet-50, sería el siguiente (disponible en Aula Virtual con nombre resnet50-inf_cpu.py):

```
1 from accelerate import Accelerator, ProfileKwargs
2 import torch
3 import torchvision.models as models
4 import torchvision.transforms as transforms
5
6 # Load ResNet-50 model
7 model = models.resnet50(pretrained=True)
8 model.eval()  # Set model to evaluation mode
9
10 # Define image transformations
11 transform = transforms.Compose([
12     transforms.Resize((224, 224)),  # ResNet expects 224x224 images
13     transforms.ToTensor(),
14     transforms.Normalize(mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225])
15 ])
16
17 # Create a batch of random images (batch size 128, 3 color channels, 224x224 resolution)
18 batch_size = 128
19 input_images = torch.rand((batch_size, 3, 224, 224))  # Random image batch
20
21 # Define profiling kwargs for CPU activities
22 profile_kwargs = ProfileKwargs(
23     activities=["cpu"],  # Profile CPU activities instead of CUDA
24     record_shapes=True
25 )
```

```
26
27 # Initialize the accelerator for CPU
28 accelerator = Accelerator(cpu=True, kwargs_handlers=[profile_kwargs])
29
30 # Prepare the model for CPU execution
31 model = accelerator.prepare(model)
32
33 # Move inputs to CPU
34 device = accelerator.device
35 input_images = input_images.to(device)
36
37 # Profile the model execution on the CPU
38 with accelerator.profile() as prof:
39     with torch.no_grad():
40         outputs = model(input_images)  # Forward pass
41
42 # Print profiling results
43 print(prof.key_averages().table(sort_by="cpu_time_total", row_limit=10))
```

Como puede observarse, se utilizará un modelo ResNet-50 pre-entrenado y un ejemplo de entrada ficticia con un *batch* de 128 imágenes. En la segunda imagen, se crea una instancia de Accelerator que se utilizará para llevar a cabo la predicción del batch.

Finalmente, imprimimos el tiempo total que ha necesitado la CPU para realizar el procedimiento de inferencia.

Para poder lanzar este procedimiento de inferencia, ejecutaremos el siguiente comando, asumiendo que tenemos ya configurado en el fichero ".yaml" el entorno para sistema de cómputo CPU:

```
$> accelerate launch --config_file config_cpubase.yaml resnet50-inf_cpu.py
```

Otro ejemplo de ejecución de inferencia lo podemos ver en la siguiente imagen con el modelo BERT-base-cased. BERT-base-cased es un modelo de procesamiento de lenguaje natural pre-entrenado por Google que utiliza la arquitectura *Transformer* para comprender el significado de textos en inglés, respetando mayúsculas y minúsculas. La salida de ejecución sería la de la siguiente imagen:

```
root@39229ceb2b9d:/accelerate_gpu# accelerate launch --config_file config_cpubase.yaml bert-inf_cpu.py
2025-02-25 14:50:16,590 - launch.py - accelerate.commands.launch - WARNING - The following values were not passed to `accelerate launch` a
        `--num_cpu_threads_per_process` was set to `8` to improve out-of-box performance when training on CPUs
To avoid this warning pass in values for each of the problematic parameters or run `accelerate config`.
-------------------------------------------------------  ------------  ------------  ------------  ------------  ------------  ------------
                                                  Name    Self CPU %     elf CPU   CPU total %     PU total  CPU time avg    # of Calls
-------------------------------------------------------  ------------  ------------  ------------  ------------  ------------  ------------
                                          aten::linear         0.32%     184.146ms       182.69%      104.873s     718.307ms           146
                                           aten::addmm        88.51%       50.808s        89.45%       51.351s     703.434ms            73
                                           aten::copy_         4.84%        2.777s         4.84%        2.777s       9.412ms           295
                                               aten::to         0.00%     536.520us         3.90%        2.239s      10.177ms           220
                                         aten::_to_copy         0.00%       2.217ms         3.90%        2.238s      10.175ms           220
                     aten::scaled_dot_product_attention         0.02%       8.697ms         3.89%        2.232s     186.015ms            12
     aten::_scaled_dot_product_flash_attention_for_cpu         3.87%        2.223s         3.87%        2.223s     185.290ms            12
                                                aten::add         1.05%     604.371ms         1.50%     863.042ms      34.522ms            25
                                               aten::gelu         0.65%     371.463ms         0.65%     371.463ms      30.955ms            12
                                          aten::layer_norm         0.00%     222.897us         0.59%     340.061ms      13.602ms            25
-------------------------------------------------------  ------------  ------------  ------------  ------------  ------------  ------------
Self CPU time total: 57.406s
```

Como puede observarse este procedimiento ha tardado 57,4 segundos en completarse.

En el fichero comprimido masterIDL_scripts_v2.zip de la carpeta de Recursos/Practica1 del aula virtual se tiene disponible el código para lanzar este experimento, también para entrenamiento.

3.2 Optimizaciones de ejecución: GPU

La GPU está siendo masivamente explotada como acelerador para procesamiento DL. Accelerate nos permite con ligeras modificaciones sobre el código PyTorch anterior poder ejecutar procedimientos de inferencia y entrenamiento de modelos DL. Para demostrar esto, vamos a ejecutar el mismo experimento anterior, pero sobre GPU. Para ello, tendremos que configurar Accelerate para que utilice el sistema de cómputo GPU, siempre y cuando la máquina sobre la que vamos a realizar el experimento disponga de GPU.

Para ello, utilizaremos el script bert-inf_gpu.py disponible en el fichero comprimido masterIDL_scripts_v2.zip de la carpeta de Recursos/Practica1 del Aula Virtual (inferencia con el modelo Bert-base-cased) y el fichero de configuración ".yaml" config_gpubase.yaml" para delegar el cómputo a la GPU.

```
root@39229ceb2b9d:/accelerate_gpu# accelerate launch --config_file config_gpubase.yaml bert-inf_gpu.py
-------------------------------------------------------  ------------  ------------  ------------  ---------
                                                   Name    Self CPU %      Self CPU   CPU total %     CPU to
-------------------------------------------------------  ------------  ------------  ------------  ---------
ampere_bf16_s16816gemm_bf16_256x128_ldg8_relu_f2f_st...         0.00%       0.000us         0.00%       0.00
void cutlass::Kernel2<cutlass_80_tensorop_bf16_s1681...         0.00%       0.000us         0.00%       0.00
void pytorch_flash::flash_fwd_kernel<pytorch_flash::...         0.00%       0.000us         0.00%       0.00
void at::native::vectorized_elementwise_kernel<4, at...         0.00%       0.000us         0.00%       0.00
void at::native::(anonymous namespace)::vectorized_l...         0.00%       0.000us         0.00%       0.00
void at::native::unrolled_elementwise_kernel<at::nat...         0.00%       0.000us         0.00%       0.00
void at::native::vectorized_elementwise_kernel<4, at...         0.00%       0.000us         0.00%       0.00
void at::native::(anonymous namespace)::indexSelectL...         0.00%       0.000us         0.00%       0.00
void at::native::vectorized_elementwise_kernel<4, at...         0.00%       0.000us         0.00%       0.00
void at::native::elementwise_kernel<128, 2, at::nati...         0.00%       0.000us         0.00%       0.00
-------------------------------------------------------  ------------  ------------  ------------  ---------
Self CPU time total: 948.454ms
Self CUDA time total: 635.750ms
```

Como podemos observar, en este caso el tiempo en realizarse el procedimiento de inferencia ha sido de menos de un segundo, o 57 veces más rápido que con la CPU. Nótese que, "Self CPU time" y "CUDA time total", son los tiempos que cada dispositivo ha empleado en realizar el experimento. Aquí, la CPU se ha utilizado para unas operaciones que involucran fundamentalmente inicialización de parámetros de ejecución, los tensores de los modelos DL, los pesos y activaciones, así como los ejemplos de entrada que constituyen el batch. La GPU, por el contrario, se ha encargado de realizar el cómputo de la inferencia del modelo. Estos dos tiempos no han de sumarse para saber el tiempo total de ejecución, sino que se tiene que utilizar alguna herramienta externa para medir el tiempo que el usuario ha estado esperando a que se complete el experimento. Para ello, podemos utilizar el comando Linux `time`.

Esta herramienta nos ofrece como salida:

- **real**: Tiempo total desde que se ejecutó el comando hasta que finalizó (incluye espera por I/O y otros procesos).
- **user**: Tiempo total de CPU usado por el proceso en modo usuario. Si se tienen varios hilos/cores sobre los que se ha paralelizado el experimento, user puede dar un valor que no coincide con el tiempo real de ejecución. User suma los tiempos individuales que cada hilo termina en ejecutarse.
- **sys**: Tiempo total de CPU usado en llamadas al sistema operativo.

Por ejemplo, se puede ver en la siguiente imagen el tiempo real que tarda realmente el experimento sobre CPU (sobre 63 segundos):

```
real    1m3.481s
user    7m16.946s
sys     0m20.592s
root@39229ceb2b9d:/accelerate_gpu# time accelerate launch --config_file config_cpubase.yaml bert-inf_cpu.py
```

Y sobre GPU (sobre 7 segundos):

```
real    0m7.792s
user    0m8.658s
sys     0m0.804s
root@39229ceb2b9d:/accelerate_gpu# time accelerate launch --config_file config_gpubase.yaml bert-inf_gpu.py
```

Considerando el valor de la métrica real, ahora se aprecia como el experimento se ha acelerado 9 veces.

Para excluir el tiempo que invierte la CPU en inicialización de tensores, preparación del batch, y configuración del entorno Accelerate, para medir solo el tiempo de ejecución de una sección específica dentro del código, como puede ser la inferencia del modelo o justo la sección de código para el entrenamiento, se usa "time.time()" en Python (por ejemplo, en resnet50-train_mgpu.py de masterIDL_scripts_v2.zip) o bien torch.cuda.Event para mediciones precisas en GPU.

3.3 Optimizaciones de ejecución: IPEX

Intel Extension for PyTorch (IPEX) está optimizado para CPUs con AVX-512 o superior, aunque también funciona en CPUs con solo AVX2. Se espera que mejore el rendimiento en procesadores Intel con AVX-512 o superior, mientras que en CPUs con solo AVX2 (como algunos AMD o Intel más antiguos) podría ofrecer beneficios, pero sin garantía.

IPEX optimiza el entrenamiento en CPU con precisión *Float32* y *BFloat16*. En lo que sigue adoptaremos *BFloat16* (**bf16** en Accelerate) como ejemplo. El tipo de dato de baja precisión *BFloat16* es compatible de forma nativa con los procesadores *Xeon® Scalable* de 3ª generación (*Cooper Lake*) con AVX-512 y será compatible con la próxima generación de procesadores *Intel® Xeon® Scalable* con instrucciones *Intel® AMX*, ofreciendo un mayor rendimiento.

Además, podemos configurar en Accelerate, *Auto Mixed Precision* (AMP), que es una técnica que permite entrenar modelos con una combinación de precisión de punto flotante (FP16 y FP32) de forma automática. Esto reduce el uso de memoria y acelera el entrenamiento sin afectar significativamente la precisión del modelo. AMP selecciona dinámicamente qué operaciones pueden ejecutarse en FP16 para mayor eficiencia y cuáles deben mantenerse en FP32 para estabilidad numérica.

Para poder lanzar experimentos con CPU e IPEX, tendremos que configurar en Accelerate las siguientes opciones. El fichero config_ipexbase.yaml está disponible también en masterIDL_scripts_v2.zip.

```
root@39229ceb2b9d:/accelerate_gpu# cat config_ipexbase.yaml
compute_environment: LOCAL_MACHINE
debug: false
distributed_type: 'NO'
downcast_bf16: 'no'
enable_cpu_affinity: false
ipex_config:
  ipex: true
machine_rank: 0
main_training_function: main
mixed_precision: bf16
num_machines: 1
num_processes: 1
rdzv_backend: static
same_network: true
tpu_env: []
tpu_use_cluster: false
tpu_use_sudo: false
use_cpu: true
```

3.4 Profiling de la ejecución

El *profiling* en general es el proceso de analizar el rendimiento de un programa para identificar cuellos de botella, optimizar el uso de recursos y mejorar la eficiencia. Se centra en medir aspectos como el tiempo de ejecución, el uso de CPU y GPU, el consumo de memoria y la frecuencia de llamadas a funciones. En el contexto de Deep Learning, el profiling ayuda a detectar operaciones costosas y mejorar la velocidad de entrenamiento e inferencia de modelos.

ProfileKwargs es una utilidad de Accelerate que permite configurar el profiling del rendimiento de un modelo en PyTorch. Los tipos de métricas que puede reportar son:

- **cpu_time_total**: Tiempo total en CPU
- **cuda_time_total**: Tiempo total en GPU
- **self_cpu_time_total**: Tiempo en CPU sin incluir suboperaciones
- **self_cuda_time_total**: Tiempo en GPU sin incluir suboperaciones
- **self_cpu_memory_usage**: Uso de memoria en CPU
- **self_cuda_memory_usage**: Uso de memoria en GPU
- **flops**: Operaciones de punto flotante por segundo
- **record_shapes**: Formas de los tensores usados en cada operación

Es importante destacar que, a diferencia de en otras asignaturas, nos centramos más en métricas no funcionales como el tiempo de ejecución y consumo de memoria, más que métricas de calidad del modelo entrenado como su *accuracy*. Así, para inferencia, analizaremos el número de operaciones que han sido ejecutadas, el tamaño del modelo, el tiempo de ejecución, que es independiente del accuracy. Por otro lado, en cuanto al entrenamiento, no será necesario ejecutar tantas épocas como sea preciso para obtener convergencia del modelo. Nos interesará analizar qué operaciones son más costosas en cuanto a tiempo de ejecución, cuánto aumenta el consumo de memoria del modelo cuando está siendo entrenado, etc.

Tras el proceso de ejecución que se explicó en el apartado anterior se observaban métricas de rendimiento tales como el tiempo de CPU o el de GPU. Además, podemos reportar otras métricas como el consumo de memoria modificando los scripts de los modelos anteriores (e.g., bert-inf_cpu.py) añadiendo estas líneas:

```
profile_kwargs = ProfileKwargs(
    activities=["cpu"],
    profile_memory=True,
    record_shapes=True
)
```

Después de lo anterior, vendría el código para realizar la inferencia del modelo. Y finalmente, realizaríamos el reporte de estadísticas que necesitamos:

```
print(prof.key_averages().table(sort_by="self_cpu_memory_usage", row_limit=10))
```

Así, tras ejecutar un experimento (tomado de la web de Hugging Face) obtendríamos una salida como la siguiente:

```
---------------------------------  ------------  ------------  ------------
                            Name       CPU Mem  Self CPU Mem    # of Calls
---------------------------------  ------------  ------------  ------------
                     aten::empty      94.85 Mb      94.85 Mb           205
    aten::max_pool2d_with_indices      11.48 Mb      11.48 Mb             1
                     aten::addmm      19.53 Kb      19.53 Kb             1
                      aten::mean      10.00 Kb      10.00 Kb             1
              aten::empty_strided         492 b         492 b             5
                        aten::cat         240 b         240 b             6
                        aten::abs         480 b         240 b             4
              aten::masked_select         120 b         112 b             1
                         aten::ne          61 b          53 b             3
                         aten::eq          30 b          30 b             1
---------------------------------  ------------  ------------  ------------
Self CPU time total: 69.332ms
```

Esta herramienta de profiling también permite exportar las trazas de ejecución a un fichero en formato json para poder ser visualizado por una herramienta externa, como por ejemplo *Chrome trace viewer* (en la barra de búsqueda del navegador Chrome, escribiríamos chrome://tracing para cargar el fichero de trazas generado). Esto es especialmente útil para llevar a cabo un profiling más exhaustivo con los kernels CUDA que se ejecutan en los experimentos que involucran un sistema de cómputo con GPU.

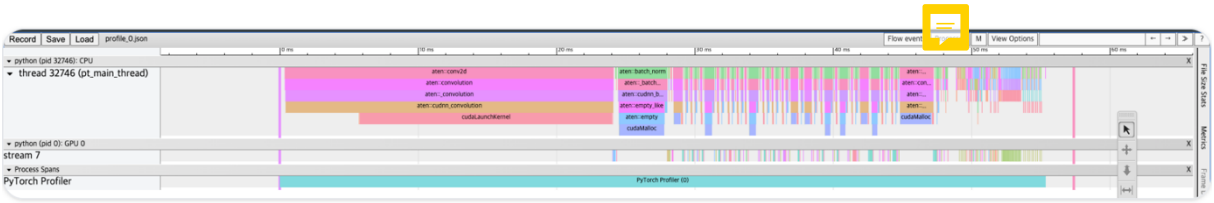

También se permite hacer profiling de experimentos que tarden demasiado (por ejemplo, experimentos de entrenamiento) añadiendo argumentos opcionales como:

- **schedule_option**: Permite controlar cuándo se activa el *profiling* para evitar recopilar demasiados datos en tareas largas. Sigue un ciclo con las siguientes fases:
- **skip_first**: Omitir los primeros pasos.
- **wait**: Esperar un número de pasos antes de iniciar.
- **warmup**: Ejecutar una fase de calentamiento.
- **active**: Registrar datos de rendimiento.
- **repeat**: Repetir el ciclo (si se especifica). Un valor de 0 mantiene el ciclo activo hasta que finaliza el perfilado.
- **on_trace_ready**: Especifica una función que recibe el *profiling* como entrada y se ejecuta cada vez que una nueva traza de datos está lista.

Al código tendríamos que añadir:

```
def trace_handler(p):
    output = p.key_averages().table(sort_by="self_cuda_time_total", row_limit=10)
    print(output)
    p.export_chrome_trace("/tmp/trace_" + str(p.step_num) + ".json")

profile_kwargs = ProfileKwargs(
    activities=["cpu", "cuda"],
    schedule_option={"wait": 5, "warmup": 1, "active": 3, "repeat": 2, "skip_first": 1},
    on_trace_ready=trace_handler
)
```

4 Tareas y puntuación asociada (máximo 8 puntos)

Para realizar las tareas de esta práctica, utilizaremos el framework Accelerate por su simplicidad, portabilidad y adecuación para permitir a los grupos de prácticas poder adquirir las competencias necesarias que permitan alcanzar los dos objetivos que se planteaban al comienzo del documento:

- *Aprendizaje de librerías y frameworks modernos para aceleración de cargas de trabajo de Deep Learning en CPU y aceleradores.*
- *Implementación y evaluación de técnicas de programación paralela para realizar procesos de inferencia y entrenamiento de modelos de Deep Learning.*

En el documento compartido en el Aula Virtual en el que aparecen los grupos de prácticas, aparecen columnas con información de las dos prácticas de la asignatura. En lo que respecta a la Práctica 1, se muestran dos categorías de columnas: una de color azul para especificar los experimentos de inferencia y la otra de color verde, para los de entrenamiento. En estas columnas, todos los grupos y el profesor tendrán una perspectiva global acerca de en qué está trabajando cada grupo de prácticas. El objetivo es que al final todos los grupos trabajen en modelos DL distintos y puedan estudiarse la mayor variabilidad de frameworks y librerías para optimización posibles.

4.1 Portado de modelos DNN a PyTorch-Accelerate (3 puntos)

Haciendo uso de Accelerate, se realizarán experimentos de inferencia y entrenamiento empleando **dos modelos de red neuronal profunda (DNN)**: uno para los experimentos de inferencia y el otro para los de entrenamiento. Estos dos modelos DNN podrían ser incluso el mismo, aunque se valorará la variedad de los mismos en cuanto a dominio de aplicación (por ejemplo, uno para visión por computador y el otro para traducción del lenguaje natural). En cualquier caso, se permite que estos modelos hayan sido utilizados en otras asignaturas durante el primer cuatrimestre, o simplemente que les sean de interés. Si los modelos estuvieron codificados en otro framework diferente a PyTorch (e.g., TensorFlow), estos modelos tendrán que ser portados a PyTorch.

A continuación, para poder hacer uso de Accelerate, se tendrán que modificar los ficheros PyTorch de los modelos añadiendo las líneas de código necesarias para configurar la clase Accelerator, adaptar el entrenamiento, inferencia, así como para añadir instrucciones para realizar *profiling* tal y como se describió en el apartado 3.

Para garantizar que no se haga un uso abusivo de los recursos computacionales del clúster ATLASv2, todo procedimiento de entrenamiento en Accelerate tardará como máximo 30 minutos en su ejecución en el peor caso, es decir, utilizando un sistema de cómputo con *backend* CPU, tal y como el de los servidores virtuales de la cola01. Esta comprobación también se podría realizar en la máquina local del estudiante.

Además, se podría estimar lo que ocupa en memoria un modelo DNN para procesos de inferencia y entrenamiento, para distintos tipos de representación de datos, utilizando el estimador de consumo de memoria de Hugging Face que viene descrito aquí. Esto sería

útil también para no agotar los recursos de memoria de nuestros sistemas de cómputo solicitados a SLURM mediante configuración de los scripts SBATCH.

Una vez confirmado el modelo o los dos modelos DNN que se van a ejecutar, el grupo de prácticas tendrá que notificarlo al profesor a través de un mensaje privado. El profesor irá dejando anotados cada uno de estos modelos en la hoja de seguimiento de los grupos de prácticas.

4.2 *Profiling* exhaustivo de inferencia y entrenamiento (3 puntos)

A continuación, se realizarán experimentos de entrenamiento e inferencia con los modelos anteriores utilizando los sistemas de cómputo descritos en el apartado 2 de este documento, pertenecientes al clúster ATLASv2 (cola01, cola02 y cola03), utilizando para ello scripts sbatch. El profesor ha dejado en Aula Virtual (masterIDL_scripts_v2.zip) ejemplos de estos scripts para entrenamiento del modelo ResNet-50.

Tras la correcta ejecución de los experimentos (no falla la ejecución), se tendrá que realizar un análisis de rendimiento en **tiempo y consumo de memoria exhaustivo** para los tres tipos de ***backend:*** CPU en cola01, GPU en cola 02 y multi-GPU en cola 03. Esto se podrá realizar partiendo de las herramientas proporcionadas por Accelerate descritas en el apartado 3, a partir de los scripts proporcionados por el profesor en el Aula Virtual, pudiendo complementarlas con otras librerías y/o herramientas que el grupo de prácticas considere para un análisis de rendimiento más exhaustivo.

En particular se pide en este apartado de *profiling* exhaustivo:

1. Saber identificar cuáles son las funciones y/o kernels que consumen más tiempo de ejecución. Se valorará que se adjunte a las estadísticas de ejecución que ofrece el *profiler* descrito en este documento, un análisis visual de alguna traza de ejecución.
2. Comprobar cómo se acelera la ejecución cuando se cambia el sistema de cómputo (e.g., cómo se reduce el tiempo de ejecución de CPU a GPU, y de GPU a Multi-GPU). Se añadirán gráficas que ayuden a interpretar los resultados y análisis realizados.
3. Estudiar algunos parámetros básicos para entrenamiento e inferencia que el grupo de prácticas considere (e.g., tamaño de *batch* o tipo de formato de los datos), y cómo afecta a las métricas de ejecución (tiempo y consumo de memoria). Se añadirán gráficas que ayuden a interpretar los resultados y análisis realizados.

4.3 Estudio de opciones de aceleración en Accelerate y/u otros *frameworks* o librerías complementarias a Accelerate (2 puntos)

Además, se valorará que el grupo estudie algunas de las posibilidades que ofrece Accelerate y que no han sido descritas en este documento (más información aquí) para optimizar el entrenamiento e inferencia de los modelos DNN utilizados. El grupo de prácticas tendrá que documentar detalladamente cómo ha conseguido instalar (si procede) el framework/librería para poder utilizarla, así como demostrar su correcta

ejecución, hacer un análisis de resultados exhaustivo (similar al apartado 4.2) que demuestre que domina adecuadamente las opciones de aceleración estudiadas.

Ejemplos serían:

Entrenamiento:

- Gradient accumulation
- Local SGD
- Low precision (FP8) training
- DeepSpeed
- Using multiple models with DeepSpeed
- DDP Communication Hooks
- Fully Sharded Data Parallel
- Megatron-LM
- IPEX training with CPU

Inferencia:

- Big Model Inference
- Distributed inference

Como se mencionó anteriormente en el apartado 2 de este documento, excepcionalmente, a petición del grupo de prácticas, también se podrá explorar funcionalidades adicionales en otros frameworks de aceleración de rendimiento y/o librerías que no estén Accelerate. En ese caso, deberán consultar su viabilidad con el profesor y, de ser aprobada, proporcionar un fichero Dockerfile con los requisitos de instalación enviándolo al profesor como mensaje privado a través del Aula Virtual.

Una vez confirmados los frameworks/librerías que el grupo de prácticas va a utilizar para optimizar los procedimientos de inferencia y entrenamiento con los cuatro modelos de DNN seleccionados, el grupo de prácticas tendrá que notificarlo al profesor a través de un mensaje privado quien lo dejará apuntado en la hoja de seguimiento de prácticas compartida en el Aula Virtual.

5 Entregables (2 puntos)

El grupo de prácticas entregará en la tarea correspondiente del Aula Virtual:

- **Memoria explicativa en formato PDF (extensión máxima de 15 páginas excluyendo portada e índice)** utilizando **obligatoriamente la plantilla .docx de entrega de prácticas (Plantilla-MemoriaPrácticas-IDL.docx)** que se encuentra en el Aula Virtual (Recursos/PRÁCTICAS). En esta memoria, se incluirán los **siguientes apartados**:
  1. **Técnicas de optimización para inferencia y entrenamiento utilizadas** para acelerar el proceso computacional dependiendo del sistema de cómputo (CPU, GPU y Multi-GPU). Se explicarán cada una de ellas detallando las ventajas que ofrecen para poder acelerar el cómputo y/o reducir el consumo de memoria. Se recomienda adjuntar diagramas explicativos que ayuden a su comprensión.
  2. **Metodología de Evaluación**:
     - Frameworks y librerías utilizadas para implementar las técnicas anteriores.
     - Soporte computacional: descripción de los nodos y colas del clúster ATLASv2 usados y, en caso de uso de máquina local, descripción de las características HW de ésta.
     - Modelos de DL seleccionados con los que se han realizado los procesos de entrenamiento e inferencia.
     - *Datasets* que se han utilizado para realizar los experimentos.
  3. **Resultados Experimentales**:
     - Demostración con capturas de pantalla de la correcta ejecución de cada uno de ellos mostrando la salida esperada.
     - Gráficos que ayuden a analizar los resultados obtenidos para cada experimento, así como el *profiling hecho*.
     - Explicación detallada de los gráficos de acuerdo con las optimizaciones realizadas.
- **Todos los ficheros de configuración (e.g., Dockerfile) y ejecución (e.g., *scripts SLURM, modelos de DL, datasets, etc.*) y listado de comandos Linux, Python, etc.** que hayan sido necesarios para poder instalar los frameworks/librerías, así como para poder ejecutar los experimentos tanto en el Clúster ATLASv2 como en máquina del estudiante (si procede) y reproducir los experimentos realizados en la práctica. Todos estos ficheros se almacenarán en un fichero comprimido (.zip) y se subirá a la tarea correspondiente de la práctica.
- **Vídeo explicativo (12 minutos máximo)**. En este video, cada uno de los miembros del grupo por turnos equitativos en tiempo y complejidad, explicará en detalle la técnica, librería o framework con la/el que se ha experimentado. Primero desde el punto de vista teórico (¿para qué se usa?), y luego el práctico (¿cómo se programa/usa? y ¿qué resultados ofrece? mostrando ejecuciones del framework sobre el que se ha trabajado). De este modo, se explicarán los resultados incluidos (gráficos) en la memoria de la práctica entregada. La duración del video será de unos 12 minutos en total (incluye la intervención de todos los miembros del grupo) y, para que pueda acceder el

profesor, se subirá a una plataforma tipo YouTube y cuyo enlace será compartido con el profesor al entregar la práctica en la tarea del Aula Virtual.